龚子亮　计算机科学与技术



电　话：17707397323　邮　箱：17707397323@163.com

23 岁 · 男 · 2 年经验 · AI 应用开发

专业技能

- **RAG 链路：**掌握 RAG 全链路开发，涵盖文档解析与版面还原、语义/章节多策略切分、Embedding 生成、BM25+向量混合检索、RRF 融合与 Rerank 精排；掌握 Query 改写与 HyDE 等查询扩展策略；具备 GraphRAG 沿知识图谱依赖链多跳检索的实战经验；基于 RAGAS 构建自动化评测体系，以 Faithfulness、Answer Relevancy、Context Precision、Context Recall 等指标评估检索与生成质量。
- **Agent 与多智能体编排：**熟练运用 LangGraph 构建可回溯、可中断的状态机 Agent，掌握 ReAct 与 Plan-and-Execute 范式选型；具备多智能体系统设计经验，熟悉 Supervisor 调度与流水线协作拓扑；熟悉 Function Calling 与工具调用失败回退机制；掌握 Dify、Coze 等 Agent 可视化编排平台。
- **模型微调与推理部署：**熟悉 DeepSeek、Qwen 等模型架构及 Transformer 核心机制；掌握 LoRA/QLoRA 参数高效微调；具备 vLLM 推理服务部署经验；熟练使用 Ollama 完成本地化部署。
- **上下文工程与记忆系统：**掌握系统指令、检索证据、对话历史与工具返回间的上下文预算分配策略；基于 Milvus+Redis 构建长短期记忆系统，涵盖增量摘要压缩与原子化记忆单元检索召回。
- **AI 协议与能力扩展：**熟悉 MCP 协议，具备自建 Server 接入内部数据源与工具的开发经验；了解 A2A 协议；掌握 Prompt Engineering（Few-shot、CoT、ReAct、结构化输出）；具备 NL2SQL 实践经验。
- **AI 应用工程化与可观测：**熟悉从原型到产品的全流程工程化，以 FastAPI + Docker + CI 完成服务封装与部署；基于 OpenTelemetry 与 LangSmith 构建 Agent 全链路可观测体系，采集耗时、Token 消耗、成功率等核心指标。

教育经历

湖南工业大学科技学院	计算机科学与技术·本科	2021.09 - 2025.06

工作经历

智企宝科技有限公司	Agent 开发工程师	2024.11—2026.09

项目经历

订单履约 AI 协同系统　2025.07-2026.09

项目介绍：面向深圳德坤物流(国家 AAAAA 级综合物流服务商)物流履约场景，针对订单异常、理赔、改派、仓储纠纷、对账、生产制造等复杂问题处理效率低、人工依赖高的问题，搭建基于大模型与 RAG 的订单履约多 Agent 协同平台。沉淀 2k+运输线路资料，4k+业务及售后文档、数十万知识片段，覆盖运价咨询、轨迹查询、订单改派、异常处理及理赔工单等场景，提升履约处置与客户服务效率。

技术栈：Python、LangChain、LangGraph、BGE-M3、Milvus、Redis、Qwen3-14B、LoRA 微调、Harness

个人职责：

- **架构设计**：基于 LangGraph 构建主从 Agent 架构：主控 Agent 实现推理式任务拆解→动态路由→执行轨迹反馈→局部重规划闭环，驱动订单查询 Agent、知识检索 Agent、工单履约 Agent、理赔对账从 Agent 协同执行，适配订单

拦截、改派、异常纠纷等复杂业务。

- **记忆管理**：基于 PostgreSQL + Redis + Milvus 构建 Agent 记忆与状态管理体系，实现任务状态、短期会话缓存、客户历史订单记录、履约工单上下文、客户偏好及动作日志管理，保障多轮咨询、订单异常排查、理赔售后处理、生产进度的连续性和可靠性。
- **RAG 检索**：面向运输线路、运价规则、订单履约及售后文档，完成文档清洗、切片与索引构建；基于向量检索和关键词检索，结合元数据过滤及精排，支撑数十万知识片段的多路召回，提升复杂物流问题的检索相关性与回答可信度。
- **模型微调**：面向物流运价、零担运输、生产制造规则、客服话术等场景，构建 4K+ 条指令数据集，基于 Qwen3-14B LoRA 微调，在固定评测集上，将工具调用成功率由约 87% 提升至约 95%，意图识别准确率提升约 2 个百分点。
- **风险分层与防护**：针对查询、改派、理赔、订单变更等操作建立风险分级策略，结合 Prompt Guardrail、权限校验、参数校验及人工确认机制，对高风险操作进行拦截与审批，保障 Agent 工具调用与业务执行安全。

项目成果：平台完成生产落地，支撑日均数千次咨询与订单履约任务，推动订单查询、异常处理、改派及理赔等流程由人工串行处理转为多 Agent 协同执行，提升履约处置与客户服务效率。

车载智能终端 AI 智能决策平台 2024.11-2025.06

项目介绍：针对深圳车联智控科技有限公司车载智能终端业务，解决远程监控、设备运维、故障诊断等场景数据分散、响应滞后问题，构建多智能体协作决策平台。融合实时车况、设备数据、历史故障及企业知识库，通过 RAG、多 Agent 协同及工具调用，实现故障诊断、风险预警、远程运维等业务闭环，提升异常处理与运维决策效率。

技术栈：Python、LangGraph、FastAPI、DeepSeek-V3、Tavily、RAGFlow、WebSocket、MySQL、Redis

个人职责：

- **架构设计**：主导设计“1 主+N 专”多智能体架构，实现故障诊断、运维调度、预案匹配三类子智能体并行协作。
- **知识构建**：基于 RAGFlow 建设车载终端私有知识库，完成设备手册、维修案例及运维规范的结构化入库与向量检索；结合 Tavily 实时数据检索，构建“私有知识库 + 互联网”的双源检索机制，通过来源优先级、证据校验与冲突处理，提升信息时效性并降低事实性错误。
- **服务搭建**：基于 FastAPI、Uvicorn 与 WebSocket 搭建异步高性能服务，采用 asyncio 处理并发请求与实时通信，结合 ContextVars 实现上请求链路下文隔离；在压测环境下稳定支撑 200+ 并发连接，服务端消息处理延迟控制在 100ms 以内。
- **提示词工程**：基于 DeepSeek-V3 开发车载运维专属高阶提示词(HOPs)，实现处置方案的标准化输出与工具调用智能决策，模型输出格式校验通过率 95%，无效接口请求大幅降低。
- **成本管控**：设计多层级 Token 预算管理，按用户/场景/子 Agent 配置单次会话、单日、单月的 Token 消耗上限，超限时自动降级为规 则引擎兜底或人工介入，保障服务不超预算。

项目成果：平台上线后，故障诊断平均响应时间由 180 秒缩短至 5 秒，运维工单处理效率达到原来的 3 倍，日均稳定处理 8000+ 次请求；通过标准化诊断与自动化任务流转，提升诊断结果一致性，减少人工重复排查和流程干预，保障业务持续稳定运行。

自我评价

- 抗压能力突出，敢于迎接挑战，能适应加班与高强度节奏，富有团队精神，对工作保持持久热情。
- 沟通能力强，擅长组织协调，能迅速融入新环境；遇到突发问题能保持冷静、沉着应对并高效解决。
- 乐观务实、认真细致，心态稳定、生活规律，能适应项目快节奏，愿意长期稳定投入，与团队共同成长。